

Résumé de l'avancement de mon stage : du lundi 19/06/23 au jeudi 20/07/23

1/ J'ai tout d'abord commencé par effectuer un état de l'art sur les approches de vision par ordinateur (segmentation d'images, classification d'images, détection d'objets, suivi d'objets) pour l'agriculture intelligente (détection de maladies des plantes, suivi de la croissance des cultures, détection des mauvaises herbes, estimation de la maturité des fruit, reconnaissance des plantes, classification des différents stades phénotypiques, estimation des rendements...). Je ne me suis pas limité à l'imagerie classique, je me suis également renseigné sur les approches de télédétection (capteurs couvrant une large gamme de longueurs d'onde électromagnétique). Pour cette phase de documentation, je cherche à avoir une bonne vision d'ensemble des différentes tâches effectuées en agriculture intelligente grâce à la vision par ordinateur, au choix des architectures de machine learning utilisées selon les différentes tâches ainsi qu'aux performances obtenues. Comme il s'agit d'une thématique très récente, la plupart des cas d'application datent de ces dernières années et l'état de l'art évolue très rapidement.

2/ J'ai ensuite étudié les 3 datasets ci-dessous en vue d'en faire une présentation. Les dataset contiennent respectivement des images RGB de plantes infectées par certaines maladies, des images hyperspectrales de fruits ainsi qu'un tableau de propriétés biochimiques, électriques et physiques de mangues. En fournissant ces datasets en entrée à une architecture de deep learning appropriée, on peut obtenir la classification des espèces de plantes et de leur maladies (dataset 1) ainsi que la classification des différents stades de maturité des fruits (dataset 2 et 3).

[1] The PlantVillage dataset consists of 54303 healthy and unhealthy leaf images divided into 38 categories by species and disease. <https://datasets.activeloop.ai/docs/ml/datasets/plantvillage-dataset/>

[2] Measuring the Ripeness of Fruit with Hyperspectral Imaging and Deep Learning, <https://cloud.cs.uni-tuebingen.de/index.php/s/3gXr3o3gmYSbAq9>

[3] Classification of Ripeness Stage of Mango Fruit, <https://www.kaggle.com/datasets/denchai/classification-of-ripeness-stage-of-mango-fruit>

3/ J'ai ensuite étudié les 2 articles ci-dessous traitant d'intelligence artificielle explicable (XAI) en vue d'en faire une présentation. Le premier article s'intéresse aux mécanismes d'auto-attention dans les Vision Transformers (ViT) dans le cas pratique de la classification de cultures agricoles et cherche à établir un framework d'explicabilité. Les poids des motifs d'attention du Vision Transformer permettent d'identifier les dates clés. En ajoutant à cela la connaissance d'expert (indice NDVI), il est possible de déterminer les événements phénologiques pour la classification des différentes cultures agricoles. Le second article présente l'utilité d'utiliser des « Fuzzy cognitive maps » dans le cadre de l'XAI pour palier à l'opacité des modèles de deep learning. Les fuzzy cognitive maps permettent de modéliser la connaissance humaine en utilisant des graphiques comprenant des concepts et leurs relations et apportent des prises de décision face à l'incertitude. Selon l'auteur, combiner les approches de deep learning et les fuzzy cognitive maps permettrait d'obtenir des solutions d'IA robustes et explicables. Toujours dans le cadre de l'XAI, je m'intéresse également à la technique LIME qui permet d'identifier les caractéristiques importantes pour une prédiction de deep learning en leur attribuant un coefficient.

- [1] I. D. Apostolopoulos et P. P. Groumpos, « Fuzzy Cognitive Maps: Their Role in Explainable Artificial Intelligence », *Applied Sciences*, vol. 13, n° 6, Art. n° 6, janv. 2023, doi: 10.3390/app13063412.
- [2] I. Obadic, R. Roscher, D. A. B. Oliveira, et X. X. Zhu, « Exploring Self-Attention for Crop-type Classification Explainability ». *arXiv*, 24 octobre 2022. doi: 10.48550/arXiv.2210.13167.

4/ Par la suite, il est décidé que je vais travailler en relation avec des chercheurs de l'université d'UniLasalle Rouen, qui ont capturés des images hyperspectrales de plantes semi-aquatiques soumises à un stress hydrique au fil du temps. J'étudie donc plus en détails les spécificités des images hyperspectrales ainsi que la façon de les manipuler sur python.

Je m'intéresse alors à 2 articles en relation avec cette expérience. Le premier traite de la classification d'images hyperspectrales de fruits (kiwis, avocats) selon leur maturité à l'aide d'un réseau neuronal convolutionnel hyperspectral. Il présente la technique du gradient intégré, qui permet d'identifier les caractéristiques importantes (spatiales ou longueur d'onde) de l'enregistrement hyperspectral pour la prédiction. L'article présente également comment l'utilisation d'un encodeur permet de générer des images en fausses couleur et donc de visualiser le processus de maturation. Le second article s'intéresse à la détection du stress hydrique chez les plants de framboises à l'aide de l'imagerie hyperspectrale. L'article met en évidence l'impact du stress hydrique sur les caractéristiques biophysiques et hyperspectrales des plants de framboise. On observe des différences significatives dans les caractéristiques biophysiques des plantes et dans le spectre de réflectance de la canopée entre les plants soumis au stress et ceux qui ne le sont pas. L'imagerie hyperspectrale peut donc être utilisée pour identifier les différentes réponses au stress des plantes chez les framboisiers.

- [1] L. A. Varga, J. Makowski, et A. Zell, « Measuring the Ripeness of Fruit with Hyperspectral Imaging and Deep Learning ». *arXiv*, 20 avril 2021. doi: 10.48550/arXiv.2104.09808.
- [2] D. Williams, A. Karley, A. Britten, S. McCallum, et J. Graham, « Raspberry plant stress detection using hyperspectral imaging ». *bioRxiv*, p. 2023.02.22.529512, 22 février 2023. doi: 10.1101/2023.02.22.529512.

Je m'inspire donc de ces 2 articles pour proposer une méthode de classification des images hyperspectrales des plantes semi-aquatiques soumises à un stress hydrique. Le dataset est constitué de 48 images hyperspectrales capturant la réaction des plantes soumises à différents traitements de stress hydrique à raison d'1 image par heure pendant 8 heures pour 6 plantes différentes et 3 traitements différents. Je cherche également à identifier les signatures spectrales de stress chez la plante semi-aquatique en analysant les réponses aux différents traitements.

J'apprends ensuite à lire les images hyperspectrales reçues sur python, à visualiser une bande spectrale spécifique, à afficher le spectre d'un pixel spécifique de mon image, à afficher une image en couleurs en utilisant une combinaison de 3 bandes. Je visualise alors l'évolution de chacune des plantes lors de l'expérience et je distingue bien la différence de réponse selon les traitements.

Pour les jours à venir, je vais demander aux chercheurs qui m'ont envoyé les images hyperspectrales s'il est possible d'obtenir une labellisation de ces images (3 catégories pour le stress hydrique ?), puis j'essaierai d'entraîner un modèle de réseau neuronal convolutionnel hyperspectral sur ces images voir ce que j'obtiens. Pour le prétraitement, les images seront augmentées pour pallier au manque de données (rotation, retournement horizontal et vertical, random noise et random cut), les données seront normalisées et on effectuera une extraction de l'arrière-plan. En utilisant la technique du gradient, il sera possible de voir les longueurs d'onde qui ont le plus d'impact sur les prédictions et donc d'effectuer une sélection des bandes spectrales pertinentes. Je vais également continuer à

regarder certaines études sur la détection du stress hydrique grâce aux images hyperspectrales voir si je trouve des informations pertinentes.